



Nombre y Apellido:

Fecha:

Programa Formativo		Código Curso Acción Formativa	
Nombre Acción Formativa	PROCESAMIENTO BIG DATA CON SCALA		

DATOS PERSONALES DEL ALUMNO	
FECHA	
APELLIDOS	
NOMBRE	
N.I.F / N.I.E.:	
FIRMA:	

PRUEBA PRACTICA FINAL

ESPECIALIDAD FORMATIVA PROCESAMIENTO BIG DATA CON SCALA (IFCD0115)

INSTRUCCIONES

1. **Lea atentamente** todas las instrucciones antes de empezar.
2. La prueba practica consta de responder cada uno de los pasos propuestos.
3. Responde cada paso según la tecnología o el stack a utilizar, es decir: Si son notebooks responde en celdas separadas o los códigos en .scala y .sbt si utilizas IntelliJ Idea.
4. No penalizan los errores.
5. Puntuación: Los pasos 1, 2, 6 y 7 valen 1 punto cada uno. Los pasos 3, 4 y 5 valen 2 puntos cada uno.
6. **Apague el teléfono móvil.**

Por favor, asegúrate de responder todas las preguntas.

PROYECTO INTEGRADOR FINAL

Pipeline ETL + Análisis + Visualización con Delta Lake y Power BI

Objetivo general:

Construir de forma completamente autónoma un proyecto de datos end-to-end que integre todas las competencias del curso:

- Ingesta y modelado de datos



Nombre y Apellido:

Fecha:

- Limpieza y transformaciones con Spark
- Persistencia en Delta Lake
- Cálculo de KPIs de negocio
- Informe técnico y dashboard en Power BI Desktop

No se proporciona código. No se proporciona dataset. No se proporciona dominio de negocio. Tú defines el problema, los datos y la solución.

Entorno de trabajo — elige uno.

Antes de comenzar, declara en tu documentación qué entorno has elegido.

Vía	Entorno	Almacenamiento	Visualización
A	Azure Databricks (Runtime 16.4 LTS — Scala 2.13 / Spark 3.5.2)	Delta Lake en Unity Catalog Volumes	Power BI Desktop
B	Jupyter Notebook + Almond kernel (Scala 2.13.18 / Spark 4.1.1)	Delta Lake local	Power BI Desktop
C	IntelliJ Community + spark-submit (Scala 2.13.18 / Spark 4.1.1)	Delta Lake local	Power BI Desktop

Sea cual sea la vía elegida, los entregables y los criterios de evaluación son idénticos. La diferencia está únicamente en la infraestructura que utilizas para ejecutar el código.

Estructura de entregables

Al finalizar deberás entregar una carpeta (o repositorio) con esta estructura mínima:

- proyecto_final_[tu_nombre]/
 - datos/ ← fuentes originales utilizadas
 - etl/ ← código fuente de la ETL
 - analisis/ ← código fuente del análisis y KPIs
 - delta/ ← tablas Delta generadas (si es local)
 - informe/informe_proyecto.pdf ← exportado desde Word, Notion o similar
 - dashboard/dashboard_proyecto.pbix ← fichero Power BI Desktop



Nombre y Apellido:

Fecha:

Pasos que debes completar

PASO 1 — Define el dominio de negocio y el problema

Qué debes hacer:

1. Elige un dominio de negocio real o verosímil. Ejemplos de orientación (no son obligatorios): comercio electrónico, logística, sanidad, turismo, sector energético, banca, recursos humanos, deportes, educación.
2. Escribe en tu informe un párrafo que describa la empresa ficticia, su actividad y el problema de datos que vas a resolver.
3. Formula al menos 3 preguntas de negocio concretas que tu análisis deberá responder. Ejemplo de formato: "¿Cuáles son los 5 productos con mayor margen bruto en el último trimestre?"
4. Dibuja o describe el flujo de datos de tu proyecto: desde las fuentes hasta el dashboard.

Criterio de completitud: El lector del informe debe entender qué empresa es, qué problema tiene y qué preguntas se responden, sin necesidad de ver el código.

PASO 2 — Diseña y crea los datos de origen

Qué debes hacer:

5. Define al menos 2 fuentes de datos distintas (pueden ser ficheros que tú mismo generas, datasets descargados de fuentes abiertas, o una combinación).
6. Las fuentes deben tener formatos diferentes: por ejemplo, un CSV y un JSON, o un Parquet y un CSV. Se admite también una conexión a una base de datos si tu entorno lo permite.
7. Los datos deben tener un volumen suficiente para que el procesamiento con Spark tenga sentido: como mínimo 10.000 filas en la tabla principal.
8. Los datos de origen deben contener intencionalmente problemas de calidad: valores nulos, duplicados, formatos inconsistentes, registros corruptos, o columnas con tipos incorrectos. Documenta en el informe qué problemas has introducido y dónde.
9. Si generas los datos sintéticamente, incluye el script de generación en la carpeta datos/.

Criterio de completitud: Las fuentes están disponibles, son accesibles desde el entorno elegido y contienen problemas de calidad documentados.

PASO 3 — Construye la capa Bronze (ingesta raw)

Qué debes hacer:

10. Lee las fuentes originales con Spark sin aplicar ninguna transformación.



Nombre y Apellido:

Fecha:

11. Añade al menos las siguientes columnas de auditoría a cada registro ingerido: fecha y hora de ingesta (ingestion_timestamp) y nombre de la fuente de origen (source_file o source_name).
12. Escribe el resultado como tabla Delta en la carpeta o volumen Bronze de tu proyecto.
13. Imprime o registra en el informe: número de filas ingeridas por fuente y schema resultante.

Criterio de completitud: Existe una tabla Delta Bronze por cada fuente, con columnas de auditoría y sin ninguna transformación de negocio aplicada.

PASO 4 — Construye la capa Silver (limpieza y normalización)

Qué debes hacer:

14. Lee las tablas Bronze y aplica un proceso de limpieza documentado que resuelva los problemas de calidad identificados en el Paso 2. Como mínimo debes abordar:
 - Eliminación o imputación de valores nulos (justifica qué estrategia usas en cada caso)
 - Deduplicación de registros
 - Corrección o descarte de formatos incorrectos
 - Conversión de tipos de datos cuando sea necesario
15. Aplica al menos una join entre dos fuentes de datos distintas.
16. Normaliza los nombres de columnas (sin espacios, en minúsculas o en camelCase de forma consistente).
17. Escribe el resultado como tabla Delta Silver.
18. Documenta en el informe: cuántos registros se eliminaron o corrigieron en cada paso, con qué criterio.

Criterio de completitud: La tabla Silver existe en Delta, está limpia, tiene un schema coherente, y el informe explica cada decisión de limpieza.

PASO 5 — Construye la capa Gold (KPIs y agregaciones)

Qué debes hacer:

19. A partir de la tabla Silver, calcula al menos 5 KPIs de negocio que respondan directamente a las preguntas formuladas en el Paso 1. Cada KPI debe estar nombrado, tener una definición clara y un valor numérico calculable.
20. Los KPIs deben incluir al menos:
 - Una métrica de volumen (conteo, suma)
 - Una métrica de ratio o porcentaje
 - Una métrica temporal (evolución por mes, semana o día)
 - Una métrica de ranking o top-N



Nombre y Apellido:

Fecha:

21. Organiza los resultados en al menos 2 tablas Gold distintas con granularidades diferentes (por ejemplo, una a nivel de producto y otra a nivel de cliente, o una diaria y otra mensual).

22. Escribe las tablas Gold en Delta.

23. Para cada KPI, documenta en el informe: fórmula de cálculo, valor obtenido y breve interpretación de negocio.

Criterio de completitud: Existen al menos 2 tablas Gold en Delta, con 5 KPIs calculados, documentados e interpretados.

PASO 6 — Exporta los datos para Power BI

Qué debes hacer:

24. A partir de las tablas Gold, genera ficheros CSV o Parquet que Power BI Desktop pueda leer directamente desde disco (si usas la Vía B o C) o exporta desde Databricks (si usas la Vía A).

25. Asegúrate de que los ficheros exportados tienen cabeceras limpias, tipos correctos y no contienen columnas innecesarias para la visualización.

26. Documenta en el informe la ruta o ubicación de los ficheros exportados y el formato elegido.

Criterio de completitud: Existen ficheros exportados que Power BI puede importar sin errores.

PASO 7 — Construye el dashboard en Power BI Desktop

Qué debes hacer:

27. Importa los ficheros exportados en el Paso 6 en Power BI Desktop.

28. Si tienes varias tablas, crea las relaciones necesarias en el modelo de datos de Power BI.

29. Construye un dashboard con al menos 4 visualizaciones distintas que respondan a las preguntas de negocio del Paso 1. Debes incluir:

- Al menos una visualización temporal (gráfico de líneas o área)
- Al menos una visualización de comparación (barras, columnas o treemap)
- Al menos una tarjeta (Card) con un KPI clave
- Al menos una visualización adicional de tu elección (mapa, dispersión, embudo, tabla, etc.)

30. Añade segmentadores (slicers) que permitan filtrar por al menos 2 dimensiones relevantes (por ejemplo, por fecha y por categoría).

31. Cuida el diseño: usa un título claro, un color corporativo consistente y etiquetas comprensibles para cualquier persona no técnica.



Nombre y Apellido:

Fecha:

32. Exporta el dashboard a PDF (Archivo → Exportar → Exportar a PDF) e inclúyelo en la carpeta informe/.

33. Guarda el fichero .pbix en la carpeta dashboard/.

Criterio de completitud: El fichero .pbix se abre sin errores, contiene al menos 4 visualizaciones, 2 segmentadores y el PDF exportado está incluido en los entregables.

PASO 8 — Redacta el informe técnico

Redacta un documento (PDF de entre 4 y 8 páginas) que incluya las siguientes secciones. No es necesario que sea extenso, pero sí preciso y bien estructurado.

34. Resumen ejecutivo (media página): qué proyecto has hecho, en qué entorno y cuáles son los tres hallazgos más relevantes.

35. Descripción del dominio y las preguntas de negocio (resultado del Paso 1).

36. Arquitectura del pipeline (diagrama o descripción del flujo Bronze → Silver → Gold → Power BI).

37. Descripción de las fuentes de datos (formato, volumen, problemas de calidad encontrados).

38. Decisiones de limpieza (qué se corrigió, qué se eliminó y por qué — resultado del Paso 4).

39. Catálogo de KPIs (tabla con nombre, definición, fórmula, valor y comentario — resultado del Paso 5).

40. Capturas del dashboard con una frase de interpretación por visualización.

41. Conclusiones y posibles mejoras: qué harías con más tiempo o recursos.

Criterio de completitud: El informe está en PDF, tiene las 8 secciones, es comprensible para alguien que no ha visto el código y no supera las 8 páginas.

PASO 9 — Revisión de calidad del código

Antes de entregar, revisa tu código contra esta lista:

- ☐ El código compila y ejecuta sin errores en el entorno declarado
- ☐ No hay rutas absolutas que solo funcionen en tu máquina sin documentación (o están parametrizadas)
- ☐ Cada bloque de código tiene al menos un comentario que explica su propósito
- ☐ Los nombres de variables y columnas son descriptivos (no df1, df2, x, temp)
- ☐ El modo de escritura Delta está justificado (overwrite, append o merge)